VLAC-Cut 的任务进展归因
公开证据复核与免训练验证方案

研究阶段汇报 • 供导师阅读与讨论 • 2026 年 10 月 3 日

摘要

研究问题。 机器人持续操作，并不意味着指定任务持续推进。本报告围绕 VLAC-Cut 提出一个可检验的问题：目标无关操作带来的可见变化，是否可能被错误计入当前任务进展？其他研究也已报告或专门处理指令与视觉进展不匹配的困难，为这一问题提供了更广的研究依据。[7,8]

证据与边界。 我从原论文评测追到官方视频、标签和发布预测。在“把洋葱放进快递箱”示例中，6.1→8.3 秒的作者标签由 2.3 降至 -6.4，原始预测却由 -8 升至 2。补充复核发现后半段连续三个原始预测区间方向相反；小幅标签时轴扰动仍不能消除这一现象。但同视频早期退步判断正确，且遮挡、稀疏采样和标注口径仍是竞争解释。因此，局部方向不一致已经确认，目标无关操作被错误归因的机制尚未证明。[1 – 5]

研究方案。 拟冻结 VLAC-Cut，在新任务上不微调、不提供测试标签或答案示范，用“任务目标与对象关系 → 原生曲线 → 局部状态变化证据 → 有条件修订”组织推理。先用直接推进、有效准备、无关操作的对照检验问题，再比较原生模型、简单提示、加密采样与结构约束，同时衡量虚假进展、真实推进 / 恢复保留、误改率和成本。

当前定位。 已完成公开材料复核与轻量分析，未运行模型、未验证改进效果；有效准备的清晰真实对照尚缺。现阶段适合讨论是否开展有边界的诊断实验，方法独特性尚待系统核查。

一、为什么以 VLAC-Cut 为研究基底

VLAC-Cut 出自 HELP，是面向机器人执行视频的过程评价模型。输入包括任务描述、视频帧及可选规划，输出带时间戳的有符号进展。它关心执行何时推进、停滞、退步或恢复，并用曲线支持轨迹切分和训练数据选择。本轮首先研究离线进展评价，不直接宣称具备在线报警能力。[1,2]

其价值在于：已有模型能够表达非单调过程，研究可以落在现有较强能力的剩余错误上；官方又公开了代码、示例视频、标签及预测，便于把汇总指标追溯到具体行为。负进展表示状态比初始状态更差，不是普通完成百分比越界；从 -30 回升到 -20 也可能是真实恢复，不能一律截成零。[1,4]

对于轨迹筛选，若无关行为获得正向增量，它可能被误保留为有价值片段；若修正过强，则可能丢掉真实恢复与有效准备。这些是研究动机中的潜在下游影响，本报告未测量筛选质量或策略训练收益，不能把曲线改进直接等同于机器人成功率提高。

二、从原生评测追到可定位的错误

我依次核读了 HELP 正文第 4 节与评测表、附录 A.2 / A.4 / A.5、固定版本评测代码、官方示例预测和历史同视频标签。指标负责提示值得检查的环节，逐例材料负责确定错误是否真实存在；二者不能互相替代。

原论文指标	VLAC-Cut 整体结果	正确解释
MAE（Table 1）	7.56	有符号进展数值的平均绝对误差，越低越好
PRC（Table 1）	0.926	预测与标签的 Spearman 进展秩相关，越高越好
推进 AP（Table 3）	95.90%	对推进转移的平均精确率，评价排序能力
退步 AP（Table 3）	39.46%	对退步转移的平均精确率，不是判断准确率

表 1 | 作者报告结果，非本地重跑。[1] MAE、PRC 按轨迹计算后汇总；方向 AP 在相邻语义锚点的转移上计算。设标签增量为 Δg、预测增量为 Δp，推进正类为 Δg > 0、分数为 Δp；退步正类为 Δg < 0、分数为 −Δp。固定代码阈值为 0。[5] 39.46% 不能换算成 60.54% 漏检率；两类 AP 也受类分布影响，不能仅凭差距解释错因。

洋葱例的原始预测已经反向

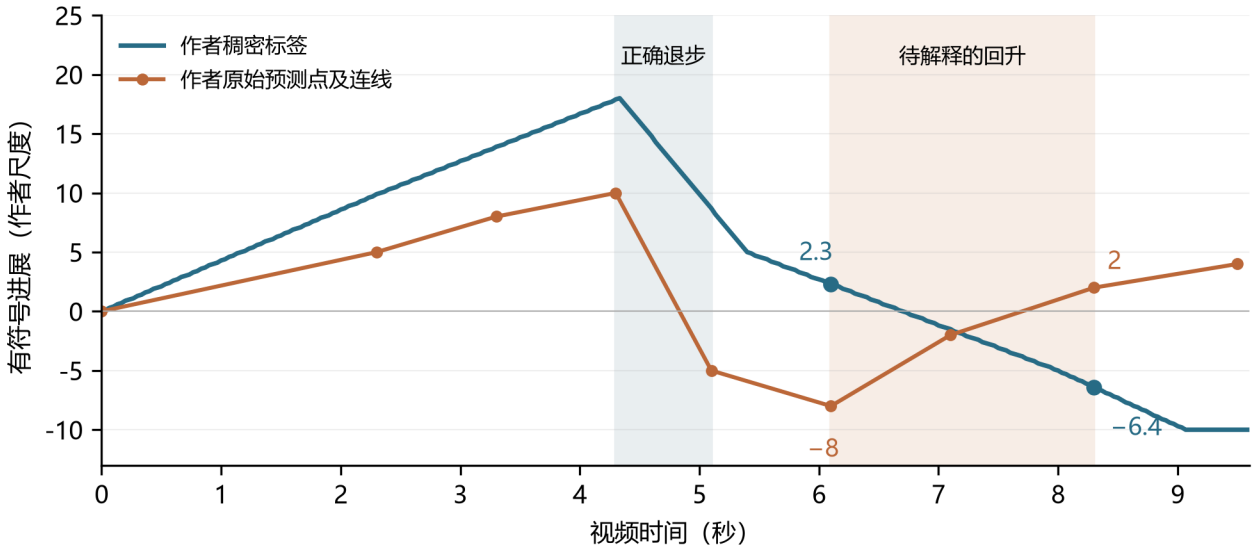


图 1 | 作者发布数据的本地重绘。[3,4] 蓝线为作者稠密标签，褐橙圆点为原始预测，连线仅便于阅读；灰色区间保留一个方向正确的退步对照，浅橙区间是主要核查窗口。所有分数沿用作者尺度，没有任何改进模型输出。

时间 / 帧（从 0 编号）	作者标签	原始预测	解释
6.1 秒 / 183 帧	2.3	−8.0	核查窗口起点
8.3 秒 / 249 帧	−6.4	2.0	核查窗口终点
区间变化	−8.7	+10.0	标签下降，预测回升

这些数值来自作者原始输出点，方向相反并非事后插值才产生。历史与当前示例视频已通过 Git blob 标识核对；洋葱例两版本的提示、原始回答和预测点一致。**这属于作者发布输出的本地复核，不是重新运行 VLAC-Cut。** 精确预测权重版本尚未完全绑定，不能将其称为论文全量评测复现。[3,4,6]

三、同一时间轴上的画面、标签与替代解释

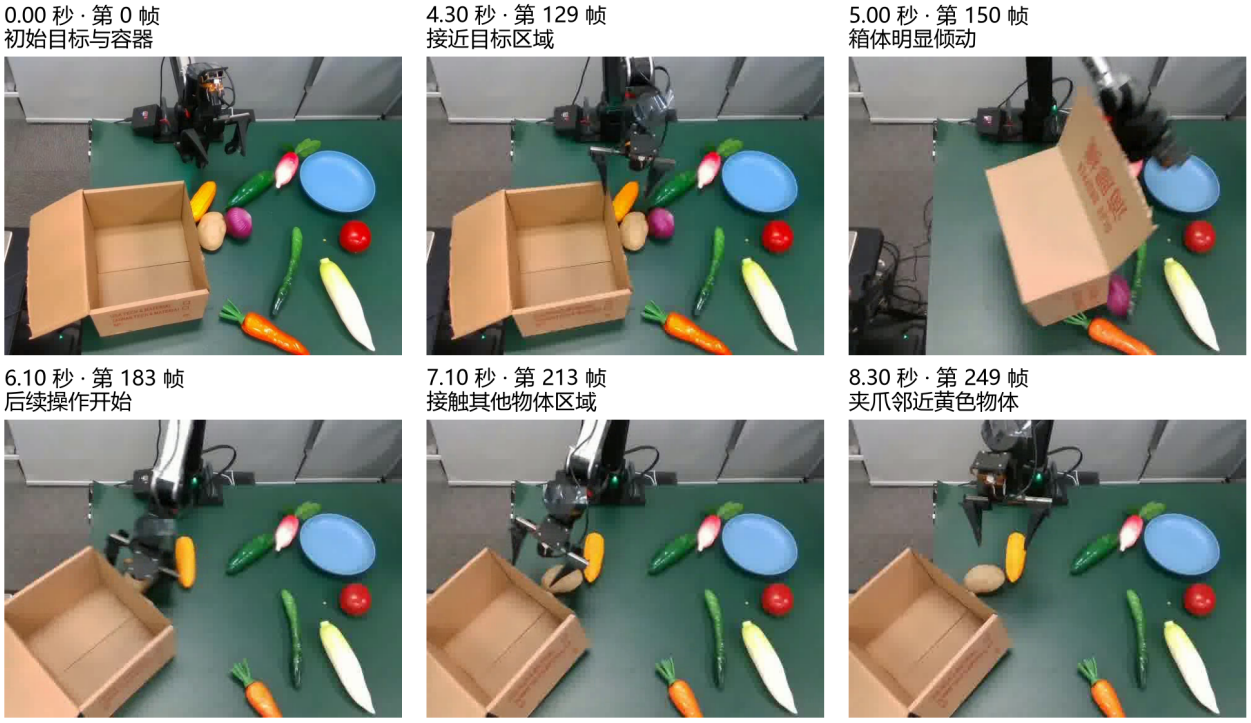


图 2 | 官方洋葱视频的原始关键帧，本地按 30 FPS 解码。[4] 展示全部画面，只缩放，不去遮挡、不补全物体。图内事件短语是本地观察；原始输出没有物体识别解释。6.1、7.1、8.3 秒帧用于事后核查，不表示它们曾是模型的输入帧。

核查窗口	可以看见或读出的证据	不能据此断言
4.3→5.1 秒	箱体明显倾动；标签增量 −9.2，预测增量 −15.0，方向一致	模型准确理解了全部接触关系
6.1→8.3 秒	后续夹爪在其他物体区域操作；未清楚看到目标恢复；标签与预测反向	洋葱的不可见位置；模型内部一定混淆物体
8.3→9.5 秒	作者标签继续下降 3.6，原始预测再增加 2.0	后续操作必然与任务完全无关

本轮补充探索实际排除了什么

原始点与采样分开核查。 6.1→7.1、7.1→8.3、8.3→9.5 秒三个相邻原始点区间均反向；4.3→5.1、5.1→6.1 秒两个较早退步区间方向正确。实际输入是 2 Hz 的 20 帧：6.1 秒位于输入的 6.0 / 6.5 秒之间，8.3 秒位于 8.0 / 8.5 秒之间。输出时间不能冒充实际观察时间。[3,6]

小幅对齐扰动。 固定发布预测，把两个标签端点各自平移 −15…+15 帧，即分别允许 ±0.5 秒误差。961 种组合的标签增量为 −13.0 至 −4.6，全部仍下降。这削弱了“小幅索引偏移即可解释反向”的解释，但不是 961 个独立样本，也不是加密采样后的模型实验。[6]

标签并非逐帧独立人工判断。 三例稠密标签与语义锚点分段线性插值的最大差约 0.05，符合一位小数舍入；论文也明确说明插值构造。[1,6] 因而下降曲线不能证明每一瞬间都在物理退步。洋葱例 162→240、240→272 帧的锚点标签也下降，预测增量分别为 +6.9、约 +2.28，说明差异不只存在于某一个稠密取值点。[6]

剩余竞争解释仍包括：稀疏输入漏掉关键动作，遮挡导致状态不确定，语义锚点对准备 / 恢复的口径不同，以及负进展的幅度标定。简单改变分数零点不会改变增量符号，但模型如何理解负进展仍需实验辨别。

四、把错例变成可证伪的研究问题

拟检验的假说是：**在动作明显而目标相关性弱的片段中，模型可能把“某个对象发生有效操作”误当作“指定任务得到推进”。** 这不是断言已发现内部机制。要验证它，必须比较视觉变化与任务作用之间的关系，不能只筛选预测回升的片段。

这一担忧也有其他研究的支持。RynnValue 的指令—轨迹配对实验发现，部分基线对不匹配指令仍呈现较明显的响应，说明视觉中的推进未必充分受指定目标约束。[7] R2VLM 则构造前段步骤相关、后段步骤无关的干扰任务描述，要求后段进展停止增加，以训练模型区分视觉变化与任务推进。[8] 前者提供相关失配现象，后者说明这一困难已被专门处理；它们支持研究动机，但不能证明洋葱例具有相同错因。

诊断类别	应检查的任务作用	目前真实材料的覆盖
直接推进	目标的必要状态或关系改善，例如抓持目标、向指定容器搬运	烧杯例可作为普通推进说明材料
有效准备	操作其他对象，但解除目标的阻挡、稳定容器或恢复可操作性	未找到可明确判定、又具配对标签的清晰案例；拟验证
无关操作	变化对目标条件及可操作性均无帮助	洋葱后半段只是候选，受遮挡限制，尚未确认类别

表 2 | 诊断定义与证据缺口。移开挡住目标的其他物体可能有帮助，不能按“对象名称不同”直接归为无关；解除阻挡也不自动等同于任务完成。正式标注另保留目标退步、真实恢复、无法判断及混合事件，避免强行三分。

正确对照约束了问题的范围

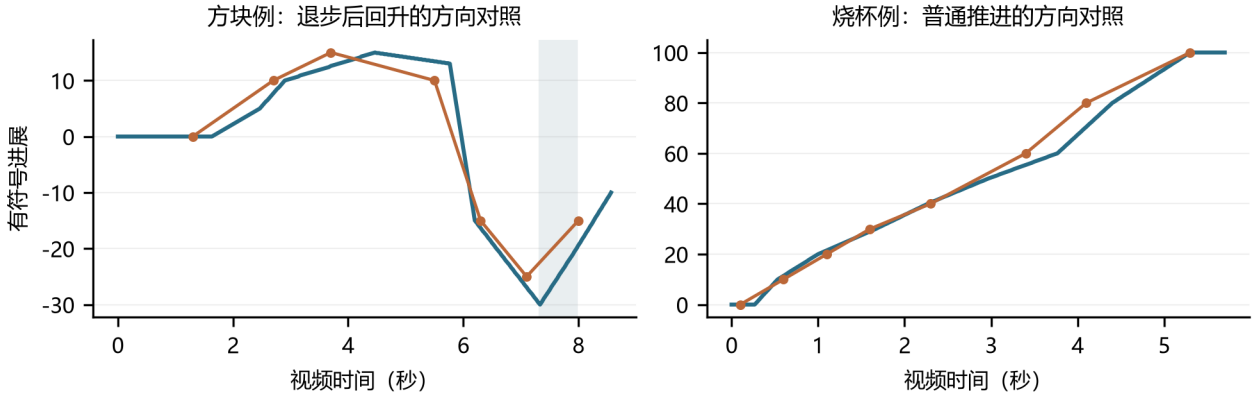


图 3 | 另两个官方展示例的标签与预测，本地重绘；颜色同图 1。[3,4,6] 方块例第 220→239 帧标签由 −30 回升到 −20，插值预测约由 −22.41 回升到 −15.37，方向一致；灰区标出该窗口。烧杯例相邻锚点的推进方向一致。图中没有本研究的修正结果。

三段视频共检查 21 个相邻语义锚点区间：方块例 8 个方向均一致，洋葱例 5 个中后 2 个反向，烧杯例 8 个均一致。方块例最后一个区间超过预测末点，采用端点保持，单独记录；上图强调的 220→239 帧不依赖这一处理。“方向一致”不代表数值完全准确。这些展示例不是随机样本，不能估计总体错误率；21 个区间也不是 21 个独立任务。[6]

如果独立样本中无关操作并不更容易触发虚假增量，或差异主要在加密采样后消失，就应收缩归因解释。如果“有效准备”与“无关操作”都被修正方法压低，则方法只学会了保守扣分，未解决研究问题。已有三例都已查看过标签，只能用于开发与说明。

五、冻结模型下的候选推理流程

从已有问题出发，探索 zero-shot 架构。 本研究的目标是检验：能否在不增加目标任务训练的条件下，用目标对象与状态证据约束已有模型的推理，减少类似的错误归因，同时保留有效准备和真实恢复。问题已被研究过，仍可以探索不同条件下的解决方法；能否形成贡献，取决于具体机制及公平对照的结果。上述相关工作提供问题依据，不意味着现有解决方法都依赖训练，也不意味着免训练架构尚无人探索。

这里的 zero-shot / training-free 指：使用已训练模型，在新任务上不更新参数、不用测试标签调规则、不提供测试答案示范。VLAC-Cut 本身经过训练；其原生提示已经可以包含百分比任务规划，训练也涉及退步 / 恢复和几何证据。[1,3] 因此不能把“增加任务分解”“使用对象信息”或“免训练”本身写成已确认创新。

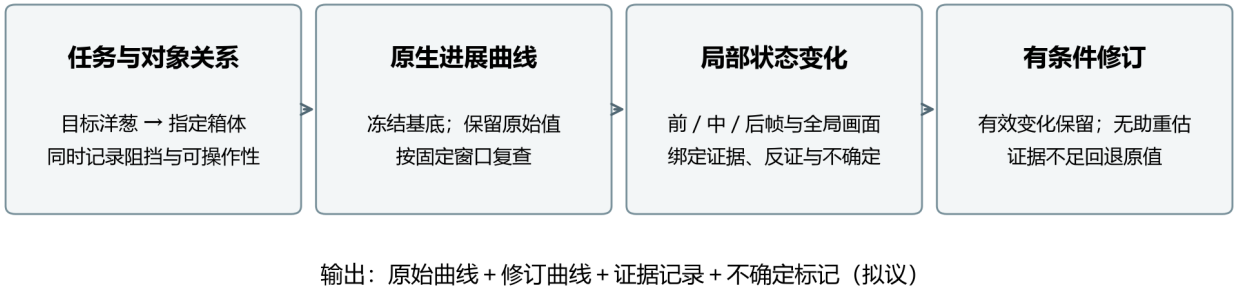


图 4 | 拟议方案示意，不是已实现或已验证的系统。输入只含任务、与基线相同的规划和允许可见的视频；所有可学习模型均冻结。输出保留原始曲线、候选修订曲线、证据记录和不确定标记，以便追溯每次改动。

第一步：明确需要建立什么关系。 从任务与已有规划提取目标对象、容器及必要关系。洋葱例至少记录“夹爪是否可靠持有洋葱”“洋葱是否进入指定箱体”，同时记录箱体是否可用、接近目标是否被阻挡。每项采用成立 / 未成立 / 不可判断，绑定支持帧。对象身份不能跨遮挡自动延续；距离变近也不能单独证明可靠抓持。

第二步：保留原生曲线并决定何时复查。 第一轮诊断先对统一时间网格的全部窗口处理，再在评价阶段映射到语义锚点，避免借测试标签指出错处。若后续压缩成本，可用原生曲线的“下降后回升”以及独立的视觉状态不确定信号触发；规则只在开发材料确定。必须抽查未触发窗口，否则看不到触发漏检和普通推进的误伤。

第三步：核对局部变化是否服务于目标。 用同一冻结模型另一次调用，查看窗口前、中、后的帧并保留全局场景，输出对象身份、关系变化、支持帧号、反证与不确定项。移开其他物体时，还要回答“原来阻挡了什么、现在是否解除”；证据不足时不能把它写成无关。若基底不能稳定输出这种结构化记录，应先报告可行性失败；引入辅助模型须另列能力与成本。

第四步：有条件重估，而非机械截断。 有清晰目标改善时保留推进，包括负值区间中的真实恢复；有解除阻挡等证据时允许准备收益，但不将其冒充最终完成。只有对象变化明确无助于目标、且状态证据足够时，才要求冻结基底在原尺度重估该段。重估以原窗口起点和未改区间作参照，检查边界跳变与符号冲突；不通过则回退原值并标记不确定。遮挡、混合事件或证据冲突默认保留原值，不能强制赋零。

复查记录至少包含窗口、目标关系前后状态、证据帧、判定类别、原始 / 修订增量和采用理由。本例尚不能填写“已确认无关”或编造修订分数。首先允许离线使用同视频后续上下文；未来若转向在线，须重做只看历史前缀的实验。

六、最小验证：先诊断问题，再检验方法

样本与标注如何避免循环论证

先用三段展示例核通数据管线，不将其用于独立效果结论。建议下一阶段从未用于本轮方法选择的官方材料中，按事先冻结的任务与物体类别抽取约 30 个独立视频，争取三类核心诊断各有 10 个清晰窗口，并保留完整轨迹中的推进、退步、恢复与不确定窗口。这个规模是探索性起点，不是统计功效保证；找不到某类时报告缺项，不用示意或合成片段补充实证。

由两名标注者在不看预测曲线的条件下，依据任务和视频标注目标身份、直接推进 / 有效准备 / 无关 / 退步 / 恢复 / 不确定及证据帧。可操作性改善与作者进展是否上升分开记录：如果“有效准备”的效用与原标签不一致，应报告标注口径冲突，不能静默改写官方真值。分歧仲裁前的比例也要保留。

模型只能得到任务、统一规划和规定帧；评价标签、语义锚点和人工对象判断均不作为输入。独立视频和任务组是统计单位，多视角或同轨迹窗口不能跨开发 / 测试分割。若需要调整触发器、阈值或提示，应另设开发样本；锁定后的保留集才用于最终比较。

需要哪些对照，怎样控制信息与计算预算

实验组	允许改变的内容	预设帧与调用预算
原生模型 B0	原生提示与曲线	2 Hz；1 次调用
简单提示 B1	提醒只给任务相关变化计分，允许准备和恢复；通用复查	2 Hz；共 3 次调用
加密采样 B2	沿用 B1，统一增加视频采样	4 Hz；共 3 次调用
结构约束 M2	对象关系记录＋状态证据＋条件重估	2 Hz；共 3 次调用
结构约束 M4	与 M2 相同，仅匹配较密输入	4 Hz；共 3 次调用

表 3 | 拟执行预算，不是已完成实验。每条轨迹共 3 次调用，分别用于初评、复查、重估；全部固定窗口在单次复查中汇总。简单组使用通用复查，结构组使用显式证据记录。每次的视觉帧集合、分辨率和输出 token 上限按配对组匹配；超长轨迹须按相同分块规则增加预算并如实记录。

B0 保留原生效率与能力参照；M2 对 B1、M4 对 B2 才是主要预算匹配比较。B2 对 B1 测试增加观测是否足够；M4 对 M2 测试采样与结构是否相互影响。所有组固定权重提交、解码配置、任务规划、可见时间范围及最终轮输出选择规则，不能挑最好的一次回答。额外报告“只有对象对应、没有状态变化约束”的消融，以检验收益落在哪个环节。

若同一视频确实支持两个不同任务，可另做固定视频、切换合法目标指令并同步修改规划的成对诊断。目标相关性由独立标注确定，不能只改目标名却保留原任务答案。该试验只能检验任务条件敏感性，不单独证明模型内部混淆了物体，也不能替代原指令下的完整轨迹评价。

七、怎样判断改进成立，以及何时停止

不能只看错误回升是否减少：输出常数也能做到，却会丢掉所有推进。评价必须同时检验抑制、保留和误改，并给每个指标明确分母。

评价项	最小可执行定义
无关操作的虚假进展	分母为盲标确认的无关窗口；分子为 $\Delta p > \varepsilon$ 的窗口，同时报告平均正增量 $\max(\Delta p, 0)$
推进 / 恢复保留	在独立标注支持且作者标签正增量的窗口，报告修订后仍为正的比例；另列原生正确窗口的保留比例
有效准备保留	单独报告准备窗口的增量分布和被压低比例；作者标签不认定推进时，另列口径分歧，不能混入成功推进
误改率	原生方向正确、修订后错误的窗口数 / 原生方向正确窗口数；在“被修改窗口”中再报一次比例
整体质量	沿固定官方协议计算 MAE、PRC、推进 / 退步 AP，并保留分任务及非专家轨迹结果
不确定与成本	不确定比例、实际修改比例、触发覆盖；总调用数、累计处理帧数、token、同硬件延迟

表 4 | 拟议评价协议。ε 是实践上的最小正增量阈值，只能预先指定或在独立开发集确定；同时报告 $\varepsilon = 0$ 的方向结果与无阈值增量，避免阈值掩盖错误。官方方向 AP 仍用其原有阈值 0，不与新增诊断阈值混用。[5]

按任务和视频先汇总配对差值，再做按任务聚类的区间估计；样本太少时只报告描述性结果和逐例结果，不以帧数制造显著性。预先公布全部选中视频的结果，包括正确保持、修正失败、错误引入和不确定回退。对象记录与帧索引便于人工核查，但模型生成的理由不是其内部机制的证明。

支持继续的条件。 独立样本重复出现任务相关性差异；结构组在相同信息和近似预算下优于简单提示与加密采样；真实推进、恢复和准备没有实质性受损。此时再扩大跨任务测试，单独研究对轨迹筛选的影响。

需要收缩或停止的条件。 现象不能重复；结果主要随时间对齐或标签口径消失；密采样或简单提示已取得相同收益；结构组频繁误改真实恢复。任一情况都应优先报告原因，而不是继续增加模块。通用复查、验证或免训练组合本身不构成已确认创新。

八、当前完成度与希望讨论的问题

目前已完成原文与固定代码核读、三例材料配对复核、原始点和锚点对照、关键帧整理，以及 ±0.5 秒对齐敏感性分析。尚未绑定发布预测的精确权重、复现全量 VPB、获得清晰有效准备对照、建立独立测试集或运行任何改进模型。本轮没有模型效果提升可以报告。

希望与导师讨论：第一，是否以“任务相关性导致的虚假进展”作为诊断问题，先不预设错因；第二，能否把有效准备与真实恢复保留列为方法成立的必要条件；第三，是否按表 3 的匹配预算开展小规模冻结模型实验。方法独特性仍需系统核查；本报告不主张该问题或对象 / 状态约束从未被研究过。

本研究的出发点是：VLAC-Cut 的局部错例提示了任务归因方面的可能困难，其他研究提供了相关问题依据，因此值得尝试以 zero-shot 推理架构改进这一环节；是否有效、是否具有方法独特性，留给后续实验回答。

参考文献与证据索引

以下链接固定到本轮所核版本，方括号编号对应正文。公开材料检索与本地复核日期为 2026 年 10 月 3 日。完整 URL、SHA-256 和计算结果随交付包保存。

[1] **原论文。** Zhai S, Zhang Q, Zhang T, et al. HELP: Human-Efficient Large-Scale Robot Post-Training with Rollout Segmentation. arXiv:2607.09776v2, 2026。重点：第 4 节、Tables 1 / 3、附录 A.2 / A.4 / A.5。固定版本全文。支持模型用途、训练与标注设计、评测数值和定义。

[2] **官方模型与评测说明。** InternRobotics, VLAC-cut。GitHub 提交：354df56ff177018f4ed3849996b3b1fc9cadedc8。README；VPB 评测说明。这是代码 / 材料版本，不等于参考预测的精确权重版本。

[3] **作者发布的原始预测。** 同上 GitHub 固定提交，examples/reference_outputs 下：example_01、example_02、example_03。包含任务、规划、实际采样帧、原始回答、预测时间与分数。

[4] **作者历史视频与标签。** Hugging Face, InternRobotics/VLAC-Cut，提交：93dc313de32258c0c81d5f50eabfe570a40d6dd6。三个示例目录；洋葱例 metadata；发布结果说明。支持视频对应关系、30 FPS、语义锚点、稠密标签以及 chunk_all / 2 Hz 示例条件。

[5] **评测实现。** 固定 GitHub 提交的 evaluate_vpb_predictions.py。重点函数 summarize_local_direction_ap、average_precision_ranked；LOCAL_DIRECTION_TAU_PERCENT = 0.0。曲线指标代码使用 Spearman，方向分数分别取预测增量与其相反数。

[6] **本地轻量复核。** 本报告配套 evidence/supplemental_checks.json、raw_points.csv、anchor_transitions.csv、alignment_sensitivity.csv，以及 prepare_evidence.py。计算只读取作者发布数据；沿用已有视频配对核查，不生成替代预测。source_manifest.json 保存所用公开文件的固定链接和哈希，previous_pairing_validation.json 保存既有配对证据。

[7] **指令与视觉进展的失配证据。** Huang D, Zhang H, Hou B, et al. RynnValue: Scaling Robotic Value Foundation Models with Temporal Distance. arXiv:2608.09853v2, 2026。固定版本全文。重点：指令失配增强、第 4.3 节及 Figure 3 的指令—轨迹对齐分析。这里只引用问题证据，不将其作为新的研究基底，也不等同于 VLAC-Cut 的局部错误。

[8] **无关步骤的进展约束。** Zhang Y, Cheng S, Li C, et al. Recurrent Reasoning with Vision-Language Models for Estimating Long-Horizon Embodied Task Progress. arXiv:2603.17312v1, 2026。固定版本全文。重点：第 3.3 节、附录 A.2 的干扰任务构造及附录 E.1 / Figure 7。该工作使用训练，不能将其效果视为本报告的 zero-shot 架构效果。

阅读结论时需要保留的边界

历史标签与当前示例视频已配对，但尚未与当前完整 split 逐条匹配；参考预测对应的精确权重未完全绑定。三个展示视频均已用于发现问题与设计方法，不能充当独立测试。原始视频、作者预测和标签未被覆盖。报告中的方法图、预算与评价协议均为拟议方案，图 1–3 才是公开材料的本地整理。

本轮有界探索到此结束：已有材料足以支持阶段讨论，却不足以消除遮挡、采样和标注口径的竞争解释。下一步最有区分力的工作是收集盲标的三类关系对照，并在固定模型与预算下做小规模推理；不是继续堆积同类错例。